

**MBA  
USP  
ESALQ**

# Utilizando aprendizado de máquina para prever resultados de jogos da NBA

Flávio Renan Sant' Anna  
Miriam Martin



## NBA - National Basketball Association

- ⊗ Liga de basquete norte-americana, fundada em 1946.
- ⊗ 30 times, divididos em 29 cidades dos EUA e 1 no Canadá.
- ⊗ Composta de 2 conferências: Leste e Oeste.
- ⊗ Temporada Regular, cada time joga um total de 82 partidas.
- ⊗ 8 Melhores times de cada conferência, classificam-se para os Playoffs.
- ⊗ A partir da temporada 2019-2020, introduzido o Play-in, mini torneio que inclui do 7º ao 10º de cada conferência, disputam as 2 últimas vagas para os Playoffs da sua respectiva conferência.
- ⊗ Playoffs, formato de mata-mata, melhor de 7 partidas.
- ⊗ Final, campeão de cada conferência.






# Objetivo




- ⊗ Prever o resultado de um jogo da NBA, 2 resultados possíveis: Vitória ou Derrota.
- ⊗ Grupos de interesse: atletas, treinadores, franquias, patrocinadores, apostadores, fãs e entusiastas.
- ⊗ Modelos utilizados: regressão logística, floresta randômica e redes neurais.
- ⊗ 2 Abordagens:
  - ⊗ 1ª Abordagem pós-jogo, analisa as estatísticas de um time após a partida, onde o adversário é desconhecido, para determinar se ele venceu ou perdeu
  - ⊗ 2ª Abordagem pré-jogo, analisa a média dos últimos 10 jogos de 2 times, para determinar o vencedor.



# Materiais e Métodos: Coleta de Dados



- ⊗ Coleta de dados, através do Site Oficial da NBA, utilizando a biblioteca Python nba\_api.
- ⊗ 12 Temporadas (2011/2012 a 2023/2024), total de 28.876 registros.
  - ⊗ Cada jogo (time A contra time B) foi representado por dois registros: um contendo as estatísticas do time A e outro com as estatísticas do time B.
- ⊗ O estudo foi realizado exclusivamente com a temporada regular, uma vez que o play-in e os playoffs apresentaram dinâmicas distintas.



# Materiais e Métodos: Tratamento dos Dados



Tabela 1. Variáveis do arquivo com os dados dos jogos.

| Variáveis         | Definição                                         |
|-------------------|---------------------------------------------------|
| SEASON_ID         | Identificador da temporada                        |
| TEAM_ID           | Identificador do time                             |
| TEAM_ABBREVIATION | Abreviação do time                                |
| TEAM_NAME         | Nome do time                                      |
| GAME_ID           | Identificador do jogo                             |
| GAME_DATE         | Data do jogo                                      |
| MATCHUP           | Times participantes do jogo                       |
| WL                | Vitória ou derrota                                |
| MIN               | Minutos jogados                                   |
| PTS               | Total de Pontos                                   |
| FGM               | Total de arremessos tentados                      |
| FGA               | Total de arremessos convertidos                   |
| FG_PCT            | Porcentagem de arremessos convertidos             |
| FG3M              | Total de arremessos de 3 pontos tentados          |
| FG3A              | Total de arremessos de 3 pontos convertidos       |
| FG3_PCT           | Porcentagem de arremessos de 3 pontos convertidos |
| FTM               | Total de lances livres tentados                   |
| FTA               | Total de lance livre convertido                   |
| FT_PCT            | Porcentagem de lance livre convertidos            |
| OREB              | Total de rebotes ofensivos                        |
| DREB              | Total de rebotes defensivos                       |
| REB               | Total de rebotes                                  |
| AST               | Total de assistências                             |
| STL               | Total de roubos de bola                           |
| BLK               | Total de bloqueios                                |
| TOV               | Total de erros                                    |
| PF                | Total de faltas                                   |
| PLUS_MINUS        | Diferença no placar (+/-)                         |



Foram excluídas variáveis irrelevantes para a pesquisa



Foi excluída a variável numérica PLUS\_MINUS (+/-), que indica a diferença de pontos ao final da partida e, por consequência, revela o resultado do jogo.




Fonte: Dados originais da pesquisa.

# Materiais e Métodos: Criação de Variáveis




## Casa (Home)



Porcentagem de vitórias para os times jogando em casa foi de 57,33%.

## Descanso (Rest)





Jogos consecutivos, impactam negativamente a porcentagem de vitórias, período ideal para preparação e descanso é 3 dias.

# Materiais e Métodos: Criação de Variáveis



## Sequência Anterior (PREV\_STREAK)



Times em uma sequência de derrotas geralmente continuam a perder, enquanto aqueles em uma sequência de vitórias tendem a manter o desempenho positivo no próximo jogo.





## Base de dados para a 1ª Abordagem

- ⊗ Cada observação possui 1 registro (1 time).
- ⊗ Variáveis relevantes da Tabela 1 + variáveis criadas.



## Base de dados para a 2ª Abordagem

- ⊗ Cada observação possui 2 Registros (2 times), dados do time e do seu oponente.
- ⊗ Média das variáveis relevantes da Tabela 1 dos últimos 10 jogos + variáveis criadas (time e oponente).
- ⊗ Foi inserido o prefixo “opp” (oponente), nos dados da segunda equipe com o objetivo de separar os dados das equipes no mesmo registro.







## Regressão Logística


- ⊗ Este método é um dos modelos de classificação mais simples e, conseqüentemente, um dos mais fundamentais.
- ⊗ Dificuldade em lidar com variáveis independentes altamente correlacionadas, fenômeno conhecido como multicolinearidade.



Variáveis com coeficientes de correlações com valores absolutos maiores que 0.8 (alta correlação), foram excluídas:

1ª Abordagem: FGM, REB e FTA

2ª Abordagem: FGM, FG3A, FTA, REB, OPP\_FGM, OPP\_DREB, OPP\_FG3A e OPP\_FTA



# Materiais e Métodos: Modelos




## Árvore de Decisão

- ⊗ Modelo simples, poderoso e de fácil interpretação. Ela operam dividindo o conjunto inicial de dados em subconjuntos progressivamente mais homogêneos (entropia e coeficiente de Gini).
- ⊗ Problema de “overfitting”, ajuste excessivo nos dados de treino.



## Floresta Randômica (Técnica Ensemble)

- ⊗ Capacidade de criar múltiplas árvores de decisão de forma independente e combiná-las para obter uma predição final mais precisa e robusta.
- ⊗ Redução da probabilidade de “overfitting”.




Exemplo de árvore de decisão, da base de dados





## Redes Neurais Artificiais (RNA)



As RNAs são inspiradas no cérebro humano, pois tem como objetivo simular a maneira como os neurônios mandam sinais uns para os outros. As redes neurais são versáteis, poderosas e escalonáveis, ou seja, são ideais para problemas grandes e complexos.



A estrutura da RNA, utilizada no estudo da 1ª Abordagem:

- ⊗ Camada de entrada: 22 variáveis
- ⊗ Camada oculta 1: 32 neurônios e função de ativação ReLU
- ⊗ Camada oculta 2: 32 neurônios e função de ativação ReLU
- ⊗ Camada de saída: 1 neurônio e função de ativação Sigmoid



A estrutura da RNA, utilizada no estudo da 2ª Abordagem:

- ⊗ Camada de entrada: 43 variáveis
- ⊗ Camada oculta 1: 64 neurônios e função de ativação ReLU
- ⊗ Camada oculta 2: 64 neurônios e função de ativação ReLU
- ⊗ Camada de saída: 1 neurônio e função de ativação Sigmoid






# Resultados: Matriz de Confusão




Tabela 2. Matriz de Confusão

|             |          | Classe Prevista |          |
|-------------|----------|-----------------|----------|
|             |          | Positivo        | Negativo |
| Classe Real | Positivo | VP              | FN       |
|             | Negativo | FP              | VN       |

Fonte: Klosterman (2019).



Caso 1



Caso 2

# Resultados: Métricas



$$\text{Acurácia} = \frac{VP+VN}{VP+VN+FP+FN}$$

$$\text{Precisão} = \frac{VP}{VP+FP}$$

$$\text{Sensibilidade} = \frac{VP}{VP+FN}$$

$$\text{Especificidade} = \frac{VN}{VN+FP}$$

$$\text{Taxa de erro} = \frac{FP+FN}{VP+VN+FP+FN}$$

$$\text{F1-Score} = \frac{2 * \text{Precisão} * \text{Sensibilidade}}{\text{Precisão} + \text{Sensibilidade}}$$

Tabela 3. Métricas dos modelos.

| Métricas       | Regressão Logística |        | Floresta Randômica |        | Redes Neurais |        |
|----------------|---------------------|--------|--------------------|--------|---------------|--------|
|                | Caso 1              | Caso 2 | Caso 1             | Caso 2 | Caso 1        | Caso 2 |
| Acurácia       | 0,843               | 0,654  | 0,813              | 0,617  | 0,834         | 0,628  |
| Precisão       | 0,847               | 0,660  | 0,816              | 0,625  | 0,891         | 0,651  |
| Sensibilidade  | 0,835               | 0,694  | 0,805              | 0,663  | 0,758         | 0,622  |
| Especificidade | 0,851               | 0,610  | 0,820              | 0,565  | 0,908         | 0,635  |
| Taxa de erro   | 0,157               | 0,346  | 0,187              | 0,383  | 0,166         | 0,372  |
| F1-Score       | 0,841               | 0,677  | 0,810              | 0,644  | 0,819         | 0,636  |

Fonte: Resultados originais da pesquisa.



No caso 1, os dados reais mantêm toda a variação e detalhes de que o modelo precisa para aprender padrões complexos e fazer previsões mais precisas. Quando usamos a média, acabamos “suavizando” os dados e perdendo informações importantes, o que pode prejudicar a precisão do modelo.



A regressão logística mostrou-se superior em quase todos os aspectos, com exceção da especificidade, na qual a rede neural artificial (RNA) teve melhor desempenho. A especificidade representa a proporção de casos negativos corretamente identificados como negativos. Em outras palavras, quanto maior a especificidade, menor a probabilidade de classificarmos falsamente algo como positivo.



A Regressão logística é o melhor modelo, portanto é o recomendado.

# Resultados: Curva ROC




A curva ROC, “Recever Operating Characteristic [ROC]”, mostra o desempenho de um modelo de classificação binária ao plotar a taxa de verdadeiros positivos, “True Positive Rate [TPR]” contra a taxa de falsos positivos, “False Positive Rate [FPR]”




A área sob a curva ROC, conhecida como “Area Under the Curve [AUC]”, indica a acurácia do classificador.

## Caso 1



## Caso 2



A qualidade e a natureza dos dados de entrada foram fatores cruciais que influenciaram diretamente o desempenho dos modelos de aprendizado de máquina.

# Resultados: Comparando com a Literatura



## Literatura

Tabela 4. Resultados de modelos extraídos da literatura.

| Modelo              | Acurácia | Autor         | Caso |
|---------------------|----------|---------------|------|
| Regressão Logística | 69,67 %  | Cao, 2012     | 1    |
| Regressão Logística | 69,10 %  | Lunelli, 2019 | 1    |
| RNA                 | 83,00 %  | Thabtah, 2019 | 1    |
| Floresta Randômica  | 57,00 %  | Saijo, 2023   | 2    |

Fonte: Resultados originais da pesquisa.

- ⊗ Caso 1: 84,30 % e Caso 2: 65,40 % (Regressão Logística)



## Discrepância dos Dados:

- ⊗ Quantidade de temporadas analisadas: média de cinco temporadas versus doze temporadas.
- ⊗ Variáveis utilizadas: As variáveis empregadas, especialmente aquelas que foram criadas para o estudo, mostraram-se de grande relevância para a eficácia dos modelos.






# Resultados: Importância das Variáveis



## Importância das variáveis (melhor modelo)



- ⊗ PTS (Pontos): Com um coeficiente de 1,09, quanto maior a pontuação, mais provável foi a ocorrência de vitória.
- ⊗ FGA (Arremessos Tentados): Com um coeficiente de -1,88, tentativas de arremesso menos eficientes (ou mais desesperadas) podem favorecer a derrota.
- ⊗ DREB (Rebotes Defensivos): Apresentou o maior coeficiente positivo, 2,00, Rebotes defensivos podem indicar uma boa defesa, contribuindo positivamente para o resultado.
- ⊗ TOV (Turnovers): Com um coeficiente de -1,29, turnovers podem ter levado a pontos fáceis para o adversário.



Deve-se ter atenção na análise das variáveis, como, por exemplo, na análise da FGA. Um alto número de FGA com uma boa porcentagem de acerto é geralmente identificado como um sinal positivo, indicando que a equipe criou e converteu boas oportunidades.

# Considerações Finais



- ⊗ Alcançou os objetivos, compatível com a literatura.
- ⊗ Sugestão de melhora futura dos modelos, principalmente no 2º Caso (Análise pré-jogo).
  - ⊗ Uma alternativa é, em vez de utilizar a média das variáveis das equipes dos últimos 10 jogos, usar o somatório das médias das estatísticas dos jogadores que irão participar da partida em questão. Assim, os dados estimados se aproximarão dos dados reais de uma partida.
- ⊗ Replicação em outros esportes: NFL e MLB, modalidades com grande quantidade de dados e estatísticas.

